




Les statistiques descriptives

—
Mesures de tendance centrale,
Mesure de dispersion et
Mesure de position

1



Les mesures de tendance centrale


▪ résumant l'ensemble des données à l'aide d'une seule valeur

▪ Ces mesures permettent de savoir :

- ce qui se passe au centre des données,
- quelles sont les valeurs centrales d'une distribution

▪ Nous verrons 3 mesures de tendance centrale :

- le mode
- la médiane
- la moyenne



2

1) La moyenne \bar{x} et μ

La moyenne représente le centre de gravité de l'ensemble des données, c.a.d. représente le centre d'équilibre des données.

- Comment la calculer ?

Voici les formules permettant de calculer la moyenne :

- Si les données sont non groupées :

Échantillon	Population
$\bar{X} = \frac{\sum x_i}{n}$	$\mu = \frac{\sum x_i}{N}$
Où x_i représentent chacune des données	

Exemple

- Soit le prix des maisons d'une rue d'un quartier. Les prix, en milliers de dollars sont les suivants :
- 167, 150, 155, 200, 210, 178, 170, 188, 189, 210
- Est-ce un échantillon ou une population ?
- Quelle est la moyenne de la variable ?

- Quel est le nombre de valeurs de x_i ?

$$\bar{X} = \frac{\sum x_i f_i}{n} \quad \mu = \frac{\sum x_i f_i}{N}$$

E " ... x_i est le nombre de valeurs de x_i qui ont une fréquence f_i dans l'échantillon de taille n .
 μ est la moyenne arithmétique des valeurs de x_i pondérées par leur fréquence f_i dans la population de taille N .

- Quel est le nombre de valeurs de x_i ?

$$\bar{x} = \mu = \frac{\sum x_i f_i}{N}$$

E " ... x_i est le nombre de valeurs de x_i qui ont une fréquence f_i dans l'échantillon de taille n .
 μ est la moyenne arithmétique des valeurs de x_i pondérées par leur fréquence f_i dans la population de taille N .

Prenons l'exemple du nombre de cours différents donnés en 2018-2019 par des profs de cégep

Cours différents	Nombre de profs	Proportion de profs
1	1	1/10
2	2	2/10
3	3	3/10
4	4	4/10
5	5	5/10
6	6	6/10
7	7	7/10
8	8	8/10
9	9	9/10
10	10	10/10

Exercices

Vous avez 5 évaluations dans la session : 2 examens qui valent 20% chacun, des devoirs et minitests qui valent 10% chacun et un final à 40%. Supposons que vous ayez eu les notes suivantes :

- Examen 1 : 40/100
- Examen 2 : 67/100
- Devoirs : 89/100
- Minitests : 70/100

Quelle note devez-vous avoir à l'examen final pour réussir le cours à 60%?

2) La médiane Md



- La médiane, que l'on note Md , est la valeur qui partage une série de données ordonnées en deux parties égales, chacune comprenant le même nombre de données.
- Pour trouver la médiane d'une série de données brutes, il faut les placer en ordre croissant et déterminer quelle valeur sépare le lot en 2 groupes identiques.

- Nombre impair de données :

On choisit la $\left(\frac{n+1}{2}\right)^e$ donnée

- Nombre pair de données :

On fait la moyenne entre la $\left(\frac{n}{2}\right)^e$ donnée et la $\left(\frac{n}{2} + 1\right)^e$ données

7

Exemples

1. Quelle est la médiane de la série suivante?

4 5 5 7 8 9 10 11 11

Donc, il a la moitié des données qui se situent au-dessus de _____ et 50% des données se situent en-dessous de _____.

2. Quelle est la médiane de la distribution suivante?

RÉPARTITION DE 56 TIRAGES CONSÉCUTIFS DU LOTTO 6/49,
SELON LE NOMBRE DE BILLETS GAGNANTS DU GROS LOT

Nombre de billets gagnants	Nombre de tirages	Cumul
0	16	16
1	12	28
2	11	39
3	8	47
4	7	54
5	1	55
6	1	56
Total	56	

8

Exercices

1. Quelle est la médiane de la série de données suivantes?

167, 150, 155, 200, 210, 178, 170, 188, 189, 210

Donc, il y a la moitié des données qui se situent au-dessus de _____ et 50% des données se situent en-dessous de _____.

Quelle est la médiane de la distribution suivante?

REPARTITION DE 75 PROPRIETAIRES D'ENTREPRISE, SELON LE NOMBRE DE VOYAGES D'AFFAIRES À L'ÉTRANGER AU COURS D'UN MOIS

Nombre de voyages	Nombre de propriétaires
0	25
1	35
2	10
3	3
4	2
Total	75

9

3) Le mode Mo

▪ Le mode est la valeur, la classe de valeurs ou la modalité qui a la plus grande fréquence. Il est significatif seulement si sa fréquence est nettement différente de celles des autres valeurs ou classes.

▪ Une distribution peut avoir plus d'un mode :

- Unimodale (1 mode)
- Bimodale (2 modes)
- Multimodale (3 modes ou plus)

▪ Une distribution peut ne pas avoir de mode si aucune valeur ne se démarque.

RÉPARTITION EN POURCENTAGE DE CONSOMMATEURS, SELON LA MARQUE PRÉFÉRÉE

Marque	Pourcentage des consommateurs (%)
A	19
B	21
C	22
D	18
E	20
Total	100

10

Exemples

1. Quel est le mode de la série suivante?

Variable : Nombre d'heures par jour passées devant l'ordinateur

Échantillon : 15 étudiants du collège

2 - 3 - 3 - 1 - 3 - 3 - 2 - 2 - 1 - 3 - 3 - 2 - 4 - 1 - 2

Mo = _____

2. Quel est le mode de la série suivante?

Variable : être fumeur ou non

Échantillon: 10 résidents de Shawinigan


f, n-f, n-f, f, n-f, n-f, f, n-f, n-f, n-f

Mo = _____

11

Exemple

Quel est le mode des distributions suivante?



12

Quelle mesure de tendance centrale utilisée?

B nfl·fn	% "a; tatnfl	:ijfi"oi;ni;fl	Variable
B f%ni;n	<ul style="list-style-type: none"> - 2))n#n; #jE~ « n#n#E· n#n#fl# - lfi; onfl - T v)n#a; f)n#af)n# fl#m· #E; # - fha#n~ n; #E~ o#m· n#n# - ;v- fla)n - B nfl·fn#n#n; la;jn#n; #a)n#a# - « }·f# v)lon 	<ul style="list-style-type: none"> - Mn· #fl·iv#s)·n;jn# - lnfl#E; ; onfl#...#p~ nfl - M}·f#E; t#e#a)j· nfi 	- Quantitative seulement
B olva;n	<ul style="list-style-type: none"> - Cn#n; #kaf#jE~ « n#n#fl#a)n·ff# - n...#p~ nfl - T v)n#n· #~ « Efin#a# fl#m· #E; # - lnfl#E; ; onfl 	<ul style="list-style-type: none"> - Cn#n; #kaf#jE~ « n# - ln#E· n#n#n#E; ; onfl 	- Quantitative seulement
B fln	<ul style="list-style-type: none"> - Mn· #lnf'v#a"nj#E· f)n#E~«n#n# - "afiai)nfl - Cn#n; #kaf#jE~ « n#n#fl#E; ; onfl# - n...#p~ nfl 	<ul style="list-style-type: none"> - :; tofinfla; #fn· n~ n; # - fl# ; n#E· # }·f)n·ff# - lfi; onfl#n# - lo~ af#·n; #n#fl# - a· #infl 	- Qualitative et quantitative

13

Les mesures de dispersion

- B nfl·fnfl >·v lfi;n;# lnfl v)ffi- a#E; fl
fl·««}~ n; #v)nfl fl·fi ·;n flobn ln lfi; onfl
>·a; #a#v)nfl·fl·fi }a~ a; vfn lfi; #fiE; #lv«nfflonfl
nfl lfi; onfl
- Anfl ~ nfl·fnfl ln lv«nfflE; lfi;n;# ; n vlon ln
}aE~ fto; owo E· uo to fto; owo }lnfl lfi; onfl
- 2))nfl atvfn; #jE~ ~ n jE~ « }~ n; #a... ~ nfl·fnfl
ln n; la;jn#n; #a)nfl
- O·a#n ~ nfl·fnfl ln lv«nfflE; fnfE; #o+lvonflø
 - }a)n;l·n
 - }ajaf# E«n
 - }a"afia;jn
 - n jfensajvni; #ln "afia#E;

14

2...n~ « h o

YÉvjv· ; tai ha· «fbfh; ai; hfl; É nflËn; î ½e · ; n..a~ n; ln ~ a ufl «É·fi" t fÉ·«nfl ln ' "

o†·lv; fl

8 fi%	√"	√	√°	—"	—√	√√	√,	—"	√—	√"	—√	—·
8 fl-	Æ,	"→	Æ,	—Æ	" "	Æ"	"√	—Æ	"—	Æ°	ÆÆ	→"

. a j · É ; fl#nfl# É% n ; n fl# n#nfl# # fÉ · «nfl#

%#

-#


15

1) L'étendue E

- L'étendue est représentée par l'écart entre la valeur maximale et la valeur minimale de l'ensemble des données de la distribution.

- $E = V_{max} - V_{min}$

- L'étendue est une mesure de dispersion très facile à calculer, mais qui ne tient compte que de 2 valeurs, la plus grande et la plus petite. C'est pourquoi on l'utilise rarement seule, mais plutôt en combinaison avec d'autres mesures de dispersion.



- Exemple précédent :

Groupe A

Groupe B

16

2) L'écart type s ou σ

- C'est la mesure de dispersion la plus utilisée, en combinaison avec la moyenne. Elle permet de préciser l'information.
- L'écart type permet de savoir comment, en moyenne, les données sont dispersées autour de la moyenne.
- Formules pour des données non groupées

3 jua; t\j}E i	ME « · }a t\E i
$s = \sqrt{\frac{\sum (x_i - \bar{X})^2}{n - 1}}$	$\sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{N}}$
E " ...v fn<fbfn; n#ua> · n#E i ; on i # · #C ##fn<fbfn; n#n#E ~ ifn#n#E i ; on	

17

2...n~ « h ø

YÉvjv· ; tai }a· «fbfn; a; t }nfl; É nflËn; î ½e · ; n..a~ n; ln ~ a t\fl «É · fi" tffÉ · «nfl ln ' "

o† · lva; #h

8 fn%	✓ "	✓	✓ °	— "	— ✓	✓ ✓	✓ ,	— "	✓ —	✓ "	— ✓	— ·
8 fn-	Æ ,	" —	Æ ,	—Æ	" "	Æ "	" ✓	—Æ	" —	Æ °	ÆÆ	— "

. a j · }É ; fl#ø jaf#%«n#n#nfl# # ffÉ · «nfl#ø

% #ø

- #ø

18

Caractéristiques de l'écart type

- L'écart type tient compte de toutes les données comme c'est le cas pour la moyenne.
- Il possède les mêmes unités que la moyenne.
- Celui-ci peut être très influencé par les données extrêmes.
- Pratiquement toutes les données se situent entre + ou - 3 écarts types, si la distribution est normale.

19

3) La variance s^2 ou σ^2

- La variance se calcule en élevant au carré l'écart type.
- Elle donne les mêmes renseignements en ce qui a trait à la dispersion des données.
- Elle est surtout utilisée en inférence statistique pour faire l'analyse de variance ou pour tester les hypothèses.

- Exemple précédent :

Groupe A

Groupe B

20

4) Le coefficient de corrélation

CV



- Le coefficient de variation est une mesure relative de la dispersion.
- Le coefficient de variation permet de comparer n'importe quel ensemble de données même si leurs moyennes sont différentes ou que les unités sont différentes.
- Le coefficient de variation indique le degré d'homogénéité des données, c'est-à-dire si les données sont homogènes ou hétérogènes.
- Les formules sont :

3 jua i t v j E i	ME « · » a t E i
$CV = \frac{s}{\bar{x}} \times 100$	$CV = \frac{\sigma}{\mu} \times 100$

- **Remarques :**
 - Si $CV \leq 15\%$ → la distribution est homogène, c.a.d. que les données sont peu ou modérément dispersées autour de la moyenne.
 - Si $CV > 15\%$ → la distribution est hétérogène, c.a.d. que les données sont assez ou très dispersées autour de la moyenne.

21

Exemple

Un travailleur qui réside sur la Rive-Sud de Montréal peut utiliser différents trajets pour se rendre au travail. Voici les statistiques qu'il a recueillies après quelques essais de ces différents parcours.

DURÉE MOYENNE (\bar{x}) ET ÉCART TYPE (s) DE LA DURÉE, SELON L'ACCÈS UTILISÉ

	Hippolyte-Lafontaine	Jacques-Cartier	Champlain	Victoria
\bar{x}	46 min	40 min	35 min	45 min
s	8,5 min	8 min	12 min	10 min

Quel trajet est le plus homogène quant au temps de parcours?

22

Les mesures de position

- La mesure de position permet de situer une donnée dans une distribution.
- Les mesures de position sont classées en deux catégories :
 - Les mesures de position absolues :
 - La médiane
 - La moyenne
 - La mode
 - Les mesures de position relatives :
 - Les quantiles
 - Les percentiles

23

1) Les quantiles

- Les quantiles sont des valeurs qui partagent une distribution en un certain nombre de parties égales.
 - o Les **quartiles** (Q_1, Q_2, Q_3) la partagent en 4 parties comprenant chacune 25% des données.
 - o Les **quintiles** (V_1, V_2, V_3, V_4) la partagent en 5 parties comprenant chacune 20% des données.
 - o Les **déciles** (D_1, D_2, \dots, D_9) la partagent en 10 parties comprenant chacune 10% des données.
 - o Les **centiles** (C_1, C_2, \dots, C_{99}) la partagent en 100 parties comprenant chacune 1% des données.

24

Procédure

Pour les données non-groupées en classes, voici la façon dont on calcule un centile :

Pour calculer le centile C_x :

°1 Ordonner les données.

°1 Déterminer la position du centile cherché :

a) Si $n \times x\%$ est un entier, le centile C_x est la moyenne entre la donnée $n \times x\%$ et la suivante.

b) Si $n \times x\%$ n'est pas un entier, le centile C_x est la donnée suivant $n \times x\%$

°1 Interprétation : Au moins $x\%$ des « unités statistiques » sont inférieures ou égales à « C_x ».

Remarque : Pour calculer un autre quantile, trouver le centile qui est équivalent.

25

Exemples

1. Soit les poids à la naissance de 10 nouveau-nés :

2350 3150 3252 3334 3552
3684 3843 3926 4125 4650

Trouver et interpréter le 2^e décile.

Interprétation : _____ % des nouveau-nés pèsent _____ de _____ g.

2. Soit les poids à la naissance de 10 nouveau-nés :

2350 3150 3252 3334 3552
3684 3843 3926 4125 4650

Trouver et interpréter le 3^e quartile.

Interprétation : Au moins _____ % des nouveau-nés pèsent _____ g ou moins.

26

2) La cote Z

La **cote Z** donne le nombre d'écarts types qui séparent une donnée de la moyenne.

$$\text{Formules : cote } Z = \frac{X - \mu}{\sigma} = \frac{\text{donnée} - \text{moyenne}}{\text{écart type}}$$

Caractéristiques de la cote Z :

- Si la cote Z est négative, alors la valeur x est sous la moyenne.
- Si la cote Z est positive, alors la valeur x est au-dessus de la moyenne.
- Les cotes Z varient généralement entre -3 et 3.
- La cote Z permet de situer un individu par rapport à son groupe.
- La cote Z permet comparer des données provenant de séries statistiques différentes.

27

Exemple

On veut trouver le meilleur vendeur du mois. Cet honneur sera accordé à la personne s'étant le plus distingué dans son domaine.

Voici la description de la performance, en un mois, de chacun des candidats :

- Lise a vendu 85 barres de chocolat, alors que la moyenne de vente a été de 52 barres par étudiant avec un écart type de 13 barres.
- Paul a vendu 25 polices d'assurance-vie, alors que la moyenne de vente est de 12 polices avec un écart type de 6.
- Lucie a vendu 75 abonnements au Journal de Québec, alors que la moyenne de vente est de 47 abonnements avec un écart type de 10.

Qui sera déclaré « vendeur du mois » ?

28

Exercices

Résultats d'un élève dans trois cours

Matière	Note de l'élève (x)	Moyenne (μ)	Écart à la moyenne ($x - \mu$)	Écart type (σ)	Cote z [($x - \mu$)/ σ]
Philosophie	85	87,5	-2,5	5	-0,5
Français	84	69	15	10	1,5
Méthodes quantitatives	80	70	10	5	2

Dans quel cours cet étudiant a-t-il le plus performé?